



**André Diogo
Gomes Ferreira**

Modelação Preditiva na Primeira Liga



**André Diogo
Gomes Ferreira**

Modelação Preditiva na Primeira Liga

Tese apresentada à Universidade de Aveiro para cumprimento dos requisitos necessários à obtenção do grau de Licenciado em Engenharia Computacional, realizada sob a orientação científica do Doutor Mário Antunes, Professor auxiliar do Departamento de Física da Universidade de Aveiro.

o júri / the jury

presidente / president

Prof. Doutor Carlos Brites

professor associado do Departamento de Física da Universidade de Aveiro

vogais / examiners committee

Prof. Doutor Mário Antunes

professor auxiliar do Departamento de Eletrónica, Telecomunicações e Informática da Universidade de Aveiro

Doutora Catarina Silva

investigadora da Universidade de Aveiro

Palavras Chave

Aprendizagem Automática, XGBoost, Previsão de Futebol, Primeira Liga Portuguesa, Calibração Probabilística, Brier Score.

Resumo

A previsão de resultados no futebol constitui um desafio complexo devido à natureza probabilística e de baixa pontuação do desporto. Este trabalho propõe uma *pipeline* preditiva baseada no algoritmo *XGBoost* aplicada ao histórico de jogos da Primeira Liga Portuguesa, avaliando o impacto da engenharia de atributos dinâmicos, da otimização hiperparamétrica com a biblioteca *Optuna* e de um *Ablation Study*. O problema foi analisado em dois cenários: multiclasse (vitória da casa, empate e vitória visitante) e binário, após a remoção dos empates. A avaliação dos modelos privilegiou a calibração probabilística das métricas *Log Loss* e *Brier Score*. Como era estatisticamente expectável, a simplificação do espaço de decisão para um cenário binário, conduziu a um aumento natural da exatidão (*Accuracy*), passando de 52,61% para 71,33%, acompanhada por uma melhoria substancial da calibração, refletida num *Brier Score* de 0,1840. Esta quantificação permite estabelecer o limite discriminatório do algoritmo *XGBoost* quando isolado da complexidade não linear introduzida pela classe do empate. Em suma, os resultados confirmam a viabilidade da utilização de *Machine Learning* para suporte avançado à previsão no futebol português.

Conteúdo

Conteúdo	i
Lista de Figuras	iii
Lista de Tabelas	v
1 Introdução	1
2 Estado de Arte	3
3 Metodologia	7
3.1 Aquisição de Dados	7
3.2 Preparação de Dados	7
3.3 Engenharia de Atributos	8
3.3.1 Normalização de Métricas	8
3.3.2 Momento de Forma e <i>Rolling Windows</i>	8
3.3.3 Diferenciais Competitivos e Fatores Exógenos	8
3.4 Modelo Multiclasse	9
3.4.1 Otimização dos Hiperparâmetros do Modelo Multiclasse (3 Classes)	9
3.4.2 Estudo de Ablação (<i>Ablation Study</i>)	9
3.5 Modelo Binário	11
3.5.1 Filtragem de Dados e Reestruturação	11
3.5.2 Otimização do Modelo Binário	11
3.6 Métricas de Avaliação	11
3.6.1 Exatidão (<i>Accuracy</i>)	11
3.6.2 Perda Logarítmica (<i>Log Loss</i>)	12
3.6.3 <i>Brier Score</i>	12
4 Resultados e Discussão	13
4.1 Avaliação Modelo Multiclasse (3 Classes)	13
4.1.1 Matriz de Confusão (3 Classes)	14

4.1.2	Curva de Calibração (3 Classes)	14
4.2	Avaliação Modelo Binário	15
4.2.1	Matriz de Confusão (2 Classes)	16
4.2.2	Curva de Calibração (2 Classes)	17
4.3	Análise Comparativa dos Modelos	17
5	Conclusões e Trabalho Futuro	21
5.1	Trabalho Futuro	21
	Referências	23
A	Gráficos de Importância de Atributos (Modelos <i>Baseline</i>)	25
B	Gráficos Complementares (Modelo de 3 Classes)	27
B.1	Matrizes de Confusão	27
B.2	Curvas de <i>Precision-Recall</i>	28
B.3	Curvas de Calibração por Classe	30
C	Gráficos Complementares (Modelo Binário)	33
C.1	Matriz de Confusão do Modelo <i>Baseline</i>	33
C.2	Curvas de <i>Precision-Recall</i>	34

Lista de Figuras

3.1	Importância relativa das 31 variáveis no modelo <i>XGBoost</i> Otimizado.	10
4.1	Matriz de Confusão para o Modelo Final Reduzido (Cenário de 3 Classes).	14
4.2	Curvas de Calibração Global Comparativas: <i>Baseline</i> , Otimizado e Final Reduzido. . . .	15
4.3	Matriz de Confusão para o Modelo Otimizado (Cenário Binário).	16
4.4	Curva de Calibração da Classe H: Comparação entre <i>Baseline</i> e Otimizado (Modelo Binário). .	17
4.5	Comparação vertical das importâncias das variáveis.	18
A.1	Importância relativa das 31 variáveis no modelo <i>Baseline</i> de 3 Classes.	25
A.2	Importância relativa das 31 variáveis no modelo <i>Baseline</i> Binário (2 Classes).	26
B.1	Matriz de Confusão para o Modelo <i>Baseline</i> (3 Classes).	27
B.2	Matriz de Confusão para o Modelo Otimizado (3 Classes).	28
B.3	Curva de <i>Precision-Recall</i> para o Modelo <i>Baseline</i> (3 Classes).	28
B.4	Curva de <i>Precision-Recall</i> para o Modelo Otimizado (3 Classes).	29
B.5	Curva de <i>Precision-Recall</i> para o Modelo Final Reduzido (3 Classes).	29
B.6	Curva de Calibração para a Classe Vitória da Casa (H).	30
B.7	Curva de Calibração para a Classe Empate (D).	31
B.8	Curva de Calibração para a Classe Vitória do Visitante (A).	31
C.1	Matriz de Confusão para o Modelo <i>Baseline</i> (Cenário Binário).	33
C.2	Curva de <i>Precision-Recall</i> - Modelo <i>Baseline</i> (Cenário Binário).	34
C.3	Curva de <i>Precision-Recall</i> - Modelo Otimizado (Cenário Binário).	34

Lista de Tabelas

3.1	Resumo das variáveis descartadas após a análise do modelo otimizado.	10
4.1	Evolução das métricas de desempenho no conjunto de teste (Modelo de 3 Classes).	13
4.2	Evolução das métricas de desempenho no conjunto de teste (Modelo Binário).	16

Introdução

Este capítulo estabelece os fundamentos do artigo, introduzindo a complexidade da modelação estatística no futebol e o enquadramento tecnológico atual das transmissões da Primeira Liga Portuguesa. São detalhadas as motivações pessoais e de mercado que impulsionaram o projeto, bem como os objetivos centrais focados na avaliação probabilística de modelos preditivos e na análise do impacto do ruído do empate. Por fim, apresenta-se a estrutura organizacional do documento.

O futebol é globalmente reconhecido como um dos desportos mais complexos e imprevisíveis de modelar estatisticamente. Devido à sua natureza de baixa pontuação (*low-scoring game*) e à forte influência de eventos aleatórios como decisões de arbitragem, lesões ou erros individuais, o desfecho de uma partida raramente reflete de forma linear a superioridade técnica de uma das equipas. Nas últimas décadas, a adoção de técnicas de *Data Science* e de *Machine Learning* revolucionou a análise desportiva. A transição de uma análise puramente qualitativa para abordagens quantitativas permitiu identificar padrões ocultos no rendimento das equipas. Contudo, a previsão do resultado final em competições de alta densidade tática, como a Primeira Liga Portuguesa, permanece um desafio estimulante para a comunidade de análise desportiva.

A motivação central para o desenvolvimento deste projeto nasce da interseção entre o profundo interesse pessoal pelo fenómeno desportivo e a ambição de consolidar competências técnicas visando uma futura integração profissional na área de *Machine Learning*, Inteligência Artificial e Análise de Dados. Adicionalmente, esta investigação é fortemente impulsionada pela assimetria tecnológica observada na transmissão televisiva do futebol europeu. Enquanto competições de topo, como a *Premier League* inglesa ou a *Bundesliga* alemã, integram nativamente estatísticas avançadas e probabilidades pré-jogo nos seus grafismos de transmissão, a Primeira Liga Portuguesa ainda carece dessa maturidade analítica no espaço mediático. O desenvolvimento de um motor preditivo robusto e bem calibrado visa demonstrar a viabilidade de introduzir este nível de profundidade estatística no contexto desportivo nacional.

Na modelação clássica de futebol, o problema preditivo é formulado em três possíveis desfechos: Vitória da Casa (H), Empate (D) e Vitória do Visitante (A). No entanto, o empate funciona frequentemente como ruído estatístico, representando uma "zona cinzenta" de difícil captação matemática. Deste modo, o objetivo principal deste trabalho consiste no desenvolvimento e avaliação de uma *pipeline* preditiva baseada no algoritmo *XGBoost*, aplicada ao histórico de jogos da Primeira Liga. Para dissecar o impacto do ruído do empate, o projeto propõe desenvolver um modelo multiclasse com otimização hiperparamétrica, seguido pela construção de um modelo binário isolado de onde os registos de empate são previamente removidos. Posteriormente, estabelece-se uma comparação direta entre as fronteiras de decisão de ambos os cenários através da métrica de *Feature Importance*. Complementarmente, assume-se o objetivo de ultrapassar a avaliação tradicional focada apenas no acerto determinístico (*Accuracy*). A avaliação é centrada na qualidade, utilidade e calibração das probabilidades geradas, recorrendo a métricas de erro probabilístico contínuo, como a Perda Logarítmica (*Log Loss*) e o *Brier Score*.

O restante deste documento encontra-se estruturado da seguinte forma. O Capítulo 2 aborda o estado da arte e a literatura técnica relevante na previsão desportiva. O Capítulo 3 descreve a metodologia de investigação e a construção da *pipeline* analítica. O Capítulo 4 apresenta a avaliação dos resultados experimentais e a discussão tática das métricas extraídas. Por último, o Capítulo 5 apresenta as conclusões e as perspetivas de trabalho futuro.

Estado de Arte

Este capítulo apresenta uma revisão detalhada da literatura técnica e científica que fundamenta a previsão de resultados no futebol. Aborda-se a transição histórica dos modelos matemáticos clássicos para os modernos algoritmos de aprendizagem automática, a justificação analítica para a seleção de arquiteturas baseadas em árvores de decisão e a complexidade estatística associada ao desfecho do empate e à validação probabilística das previsões.

A previsão de resultados em eventos desportivos tem atraído uma atenção crescente por parte da comunidade científica, impulsionada pelo aumento da disponibilidade de dados e pelo avanço do poder computacional. Historicamente, as primeiras tentativas de previsão de resultados em futebol baseavam-se em abordagens estatísticas focadas na contagem de golos. O trabalho clássico de Maher (1982) [1] introduziu a modelação através de distribuições de Poisson independentes para o ataque e a defesa de cada equipa. Contudo, a premissa de independência revelou-se matematicamente limitada. Para colmatar esta falha, o trabalho seminal de Dixon e Coles (1997) [2] proporcionou uma evolução metodológica marcante ao propor um modelo de Poisson bivariada. Ao contrário do modelo de Poisson duplo e independente, esta formulação introduziu um parâmetro de correção especificamente desenhado para incorporar a dependência estatística entre os golos marcados pelas duas equipas concorrentes, melhorando significativamente a estimativa de *scores* baixos e empates sem golos.

Apesar do sucesso histórico destes modelos matemáticos, o futebol é caracterizado por interações táticas não-lineares de extrema complexidade que desafiam as distribuições estatísticas rígidas. Com a democratização da Inteligência Artificial, a literatura científica transitou para abordagens focadas em *Machine Learning*, capazes de extrair padrões numéricos em matrizes de dados de alta dimensionalidade. O estudo de Rodrigues e Pinto (2022) [3] reflete esta evolução ao desenvolver algoritmos que agregam atributos individuais dos jogadores, englobando características e habilidades técnicas como agilidade, tempo de reação e agressividade, combinados com estatísticas coletivas de desempenho das equipas para classificar os desfechos das partidas. Atta Mills et al. (2024) [4] reforçam a superioridade das

abordagens orientadas a dados e o uso de modelos *ensemble*, demonstrando que a introdução de um processo robusto de *feature engineering*, com a criação de 28 novas variáveis dinâmicas que capturam o estado de forma e os resultados ao intervalo (*real-time features*), permite mapear as dinâmicas competitivas de forma muito mais precisa do que os métodos tradicionais. Adicionalmente, a literatura passou a contemplar fatores intangíveis que escapam aos registos puramente numéricos. A verdadeira inovação do trabalho de Beal et al. (2021) [5] residiu na introdução de técnicas de Processamento de Linguagem Natural (NLP) aplicadas a antevisões escritas por jornalistas desportivos. Afastando-se de abordagens tradicionais de mera análise de sentimentos em redes sociais, os autores focaram-se na representação vetorial de opiniões humanas e na extração de relações lógicas complexas através de sistemas de extração aberta de informação (*OpenIE*). Isto permitiu capturar variáveis dinâmicas complexas, tais como a moral do plantel, o impacto de rivalidades ou mudanças súbitas na liderança técnica, superando substancialmente os classificadores baseados apenas em sentimento textual.

No ecossistema de algoritmos aplicados ao desporto, as arquiteturas baseadas em árvores de decisão e em algoritmos de *boosting* consolidaram-se como o estado da arte. De acordo com Razali et al. (2022) [6], na previsão direta de desfechos categóricos, as variantes de *Gradient Boosting* superam consistentemente os classificadores tradicionais devido à eficiência com que processam dados tabulares heterogêneos e aos seus mecanismos internos de regularização, que mitigam o risco de sobreajuste (*overfitting*) em ambientes ruidosos. Harish et al. (2023) [7] demonstram a flexibilidade destas arquiteturas, aplicando o algoritmo *XGBoost* para estimar a probabilidade de conversão de remates (*Expected Goals* - xG) a partir de dados de eventos em tempo real. Contudo, a opacidade dos modelos complexos gerou uma preocupação crescente com a interpretabilidade. Decroos e Davis (2019) [8] alertam para as limitações de utilizar sistemas puramente opacos do tipo "caixa-negra" no contexto desportivo, tecendo críticas a estruturas pesadas de *Gradient Boosting* com centenas de variáveis e sugerindo a sua substituição por Modelos Aditivos Generalizados (*GAM*) para mapear graficamente funções univariadas exatas. O seu argumento central sublinha que compreender as razões que levam o algoritmo a emitir uma previsão é indispensável para extrair verdadeiros *insights* táticos, demonstrando que não basta listar a importância relativa das variáveis (*Feature Importance*), sendo crucial visualizar de forma transparente o impacto isolado de cada métrica na probabilidade de sucesso.

A formulação do alvo preditivo introduz outro debate metodológico crucial na literatura. Egidi e Torelli (2021) [9] contrastam os modelos baseados em golos com as abordagens focadas diretamente no resultado em três categorias (Vitória da Casa (H), Empate (D) e Vitória do Visitante (A)), notando que as distribuições geradas pelos modelos baseados no resultado são ligeiramente mais ruidosas na captura do empate. Este fenómeno é corroborado de forma empírica por Atta Mills et al. (2024) [4], que registaram consistentemente baixas métricas de precisão nesta classe, refletindo que a previsão do empate constitui um desafio universal e o grande obstáculo aos classificadores. Por esse motivo, a avaliação moderna afasta-se da dependência exclusiva da Exatidão (*Accuracy*) enquanto medida única de sucesso. Yeung et al. (2024) [10] sublinham a importância de centrar a validação na qualidade contínua e

calibração das probabilidades emitidas pelo modelo. Na persecução destas validações mais profundas, a métrica *Ranked Probability Score* (RPS) é frequentemente recomendada como ideal para desfechos de futebol por conseguir incorporar a natureza sensível à distância e à ordem das categorias (H/D/A).

Neste cenário altamente probabilístico, as chamadas *proper scoring rules* assumem um papel central na garantia do rigor do modelo. Conforme argumentado teoricamente por Decroos e Davis (2019) [8] e aplicado na validação de resultados por Egidi e Torelli (2021) [9], o *Brier Score*, métrica proposta originalmente por Brier (1950) [11], torna-se indispensável. Modelos que minimizam esta métrica de erro quadrático provam que as suas estimativas convergem rigorosamente com a frequência real de acontecimento dos eventos empíricos. Esta minimização penaliza severamente classificadores que exibam sobreconfiança em resultados incorretos, e garante que a fiabilidade matemática extraída é robusta e válida para suportar decisões analíticas avançadas no ecossistema desportivo. O uso complementar de métricas baseadas em entropia, como a Perda Logarítmica (*Log Loss*), é também recomendado sempre que se preveja a utilização das saídas de probabilidade numa lógica de processamento e combinação multiplicativa, de forma a penalizar equitativamente desvios de calibração no modelo preditivo.

Metodologia

Neste capítulo é apresentada a metodologia desenvolvida para previsão de resultados de jogos de futebol na Primeira Liga Portuguesa.

3.1 AQUISIÇÃO DE DADOS

Os dados utilizados neste projeto foram recolhidos a partir de [12], uma plataforma que fornece dados de várias ligas ao redor do mundo. O conjunto de dados é composto por registos da Primeira Liga de Portugal, abrangendo o período entre a época 2017-2018 e 16 de maio de 2026, totalizando 2754 jogos. Relativamente aos resultados observados neste histórico, registaram-se 1216 vitórias da equipa da casa, 658 empates e 880 vitórias da equipa visitante.

Embora o conjunto de dados original inclua os resultados históricos, algumas estatísticas dos jogos em cada jornada e as *odds* das casas de apostas, para este projeto apenas foram incluídos os resultados finais e o número de cartões amarelos e vermelhos obtidos. As *odds* não foram incluídas intencionalmente, de forma a permitir que o modelo possa aprender a prever os resultados sozinho, baseando-se puramente no desempenho desportivo e disciplinar das equipas.

3.2 PREPARAÇÃO DE DADOS

Em problemas de previsão de eventos desportivos, a ordem cronológica dos acontecimentos dita a forma das equipas. A aplicação habitual de *train-test split* (divisão treino-teste) de forma aleatória é desaconselhada, pois permitiria ao modelo utilizar jogos do futuro para prever jogos do passado, ocorrendo assim *data leakage* (fuga de dados).

Para garantir que não houvesse *data leakage*, os dados foram ordenados cronologicamente. O conjunto de treino foi definido desde a época 2017/2018 até à época 2023/2024 (2142 jogos), e o conjunto de teste foi estritamente isolado desde a época 2024/2025 até à época 2025/2026 (612 jogos).

Nota metodológica: Após a validação estatística da arquitetura no conjunto de teste, o modelo final destinado à previsão de jornadas futuras é novamente treinado utilizando todo o histórico disponível, de forma a incorporar a totalidade da informação recente.

3.3 ENGENHARIA DE ATRIBUTOS

Como os dados originais continham apenas resultados finais e métricas disciplinares estáticas, criou-se atributos dinâmicos para traduzir a força tática e o momento de forma das equipas. Para evitar *data leakage*, o histórico foi processado cronologicamente, jogo a jogo. Calculou-se a situação de cada clube exatamente antes do apito inicial, abrangendo pontos, golos e cartões acumulados. Estes contadores estatísticos são reiniciados no início de cada época desportiva.

Com base nestes registos, foram estruturadas três categorias de atributos preditivos:

3.3.1 Normalização de Métricas

O somatório absoluto de pontos ou golos depende diretamente da jornada atual, o que inviabiliza a comparação entre o desempenho de uma equipa na jornada 3 e na jornada 30. Para colmatar esta falha, foram criadas variáveis normalizadas por jogo:

- **Pontos por Jogo (PPG):** O total de pontos conquistados dividido pelo número de jogos disputados.
- **Diferença de Golos por Jogo (GDpg):** O saldo de golos acumulado dividido pelos jogos disputados.

3.3.2 Momento de Forma e *Rolling Windows*

Para capturar a fase atual de cada equipa, isolou-se o desempenho dos últimos 5 encontros disputados (prefixo L5), extraíndo os golos marcados, golos sofridos e pontos conquistados.

De modo a representar a evolução de forma realista, o cálculo de pontos (L5_Form_Pts) aplica uma média ponderada através do vetor de pesos $W = [1, 2, 3, 4, 5]$. O peso máximo (5) é multiplicado pelo resultado do jogo mais recente, e o peso mínimo (1) aplica-se ao confronto mais antigo. Assim, uma vitória recente detém um impacto estatístico muito superior a um resultado obtido há mais de um mês.

3.3.3 Diferenciais Competitivos e Fatores Exógenos

Construíram-se variáveis diferenciais para destacar a assimetria do confronto direto, subtraindo os indicadores da equipa visitante aos da equipa visitada. Exemplos desta abordagem incluem a diferença classificativa (Rank_Diff), a diferença de pontos por jogo (PPG_Diff) e a diferença de forma (Form_Diff).

Também se tentou mapear a influência de fatores exógenos no desfecho da partida. Idealmente, a modelação climática exigiria dados meteorológicos reais de cada estádio. No entanto, os registos fornecidos pelo Instituto Português do Mar e da Atmosfera (IPMA) apresentavam fortes limitações, estando restritos às regiões de Lisboa e Porto, além de exibirem um elevado volume de dados em falta (*missing data*).

Esta escassez inviabilizou o uso de dados meteorológicos locais oficiais para toda a liga. Como simplificação metodológica, adotou-se o calendário como uma variável *proxy*, criando-se o atributo `WeatherSeason` para categorizar as quatro estações do ano. O objetivo é testar se estas tendências sazonais macroclimáticas oferecem algum sinal preditivo.

O somatório destas transformações originou a matriz preditiva inicial composta por 31 *features*.

3.4 MODELO MULTICLASSE

3.4.1 Otimização dos Hiperparâmetros do Modelo Multiclasse (3 Classes)

O modelo preditivo inicial aborda o desfecho das partidas através de três classes: Vitória da Casa (H), Empate (D) ou Vitória do Visitante (A). Utilizou-se o algoritmo *XGBoost Classifier* com a matriz original de 31 variáveis. Para extrair o máximo desempenho do algoritmo, foi necessária uma afinação fina dos seus hiperparâmetros.

A otimização foi executada recorrendo à biblioteca *Optuna*, configurada para realizar 100 iterações (*trials*). O espaço de busca abrangeu parâmetros estruturais críticos, como a taxa de aprendizagem (`learning_rate`), a profundidade máxima das árvores (`max_depth`) e o número de (`n_estimators`). Também se incluiu os fatores de regularização L1 (`reg_alpha`) e L2 (`reg_lambda`).

Para guiar o processo de forma realista, aplicou-se uma partição interna nos dados de desenvolvimento. As épocas entre 2017/2018 e 2021/2022 (1530 jogos) integraram o conjunto de treino dos pesos das árvores. As épocas de 2022/2023 e 2023/2024 (612 jogos) serviram como conjunto de validação intermédio. A função objetivo do *Optuna* focou-se exclusivamente em minimizar a perda de entropia cruzada multiclasse (*Multiclass Log Loss*). Após o término do estudo estatístico, a combinação ideal de parâmetros foi extraída com sucesso.

Nesta iteração da *pipeline*, o modelo foi treinado com a distribuição natural do histórico de dados, sem a aplicação de pesos artificiais nas classes (*class weights*). Desta forma, a aprendizagem do algoritmo refletiu diretamente a prevalência empírica das vitórias da equipa visitada (H) e a inércia inerente ao 'fator casa' da Primeira Liga.

3.4.2 Estudo de Ablação (*Ablation Study*)

A execução do *Ablation Study* ocorreu imediatamente após a fixação dos melhores hiperparâmetros. O objetivo foi avaliar a relevância real de cada uma das 31 variáveis na estrutura do classificador otimizado. Para este efeito, o modelo foi treinado utilizando todo o bloco histórico disponível até à época 2023/2024.

Deste treino, foi extraída a importância das características segundo o critério de *feature importance* do modelo *XGBoost*. A hierarquia completa de relevância das características está representada na Figura 3.1.




Figura 3.1: Importância relativa das 31 variáveis no modelo *XGBoost* Otimizado.

A análise empírica do gráfico revelou a presença de atributos com contribuição nula ou insignificante para as decisões do algoritmo. Determinou-se a remoção cirúrgica de 7 variáveis ruidosas. A Tabela 3.1 apresenta a fundamentação teórica para estas exclusões.

Tabela 3.1: Resumo das variáveis descartadas após a análise do modelo otimizado.

Variável Removida	Justificação
WeatherSeason	Apresentou importância nula. A macro-sazonalidade baseada nas estações do ano revelou-se redundante, uma vez que a dimensão temporal já se encontra implicitamente capturada pela ordenação cronológica estrita dos dados e datas dos jogos.
Sum_HomeR / Sum_AwayR	A acumulação de cartões vermelhos foi irrelevante. Suspensões passadas raramente afetam o comportamento tático coletivo no jogo atual.
HomePoints / AwayPoints	Introduziam multicolinearidade elevada com o posicionamento classificativo (<i>Rank</i>) e com a média de pontos por jogo (PPG).
HomeW / AwayW	O somatório absoluto de vitórias provou ser uma métrica redundante face ao indicador relativo normalizado (PPG).

Esta limpeza reduziu a matriz de entrada para 24 variáveis de elevada densidade preditiva. Com este conjunto refinado, isolou-se a estrutura estável do Modelo Final de três classes. A comparação quantitativa do impacto deste corte no conjunto de teste final (épocas 24/25 e 25/26) será detalhada no Capítulo 4.

3.5 MODELO BINÁRIO

A previsão de empates é, estatisticamente, o maior desafio na modelação de futebol, gerando uma fronteira de decisão altamente complexa devido a eventos de baixa probabilidade. Para testar o limite preditivo do algoritmo num ambiente simplificado e estabelecer um *baseline* analítico, desenvolveu-se uma formulação binária do problema.

3.5.1 Filtragem de Dados e Reestruturação

O processo de conversão para duas classes iniciou-se com a filtragem do histórico de jogos. Todos os registos cujo desfecho final foi um empate ($FTR = 'D'$) foram eliminados do conjunto de dados. Foi aplicado o *LabelEncoder* para codificar a variável alvo, considerando apenas duas classes: Vitória da equipa Visitada (H) e Vitória da equipa Visitante (A).

Ao contrário do modelo de três classes, a matriz de entrada do modelo binário manteve as 31 *features* originais.

3.5.2 Otimização do Modelo Binário

Com o alvo reestruturado, treinou-se um novo classificador utilizando o algoritmo *XGBoost* configurado para regressão logística binária ($objective = "binary:logistic"$).

Seguindo a mesma metodologia de validação cruzada temporal estabelecida na Secção 3.4.1, o espaço de hiperparâmetros foi explorado com a biblioteca *Optuna*. O processo consistiu em 100 iterações otimizadas no conjunto de validação intermédio. Como resultado, obteve-se uma parametrização distinta, perfeitamente adaptada à nova fronteira de decisão (sem empates).

A análise das fronteiras de decisão deste modelo (via *Feature Importance*) e a respetiva comparação com o modelo de três classes serão detalhadas no Capítulo 4.

3.6 MÉTRICAS DE AVALIAÇÃO

Para garantir uma validação rigorosa dos modelos preditivos desenvolvidos, a avaliação detalhada no Capítulo 4 afasta-se da dependência exclusiva de métricas de acerto absoluto (*Hard Classification*), introduzindo métricas de erro probabilístico contínuo (*Soft Classification*). A implementação computacional de todas as métricas foi realizada com o recurso à biblioteca *Scikit-Learn* em *Python*, com exceção do *Brier Score* multiclasse, cuja formulação matricial foi desenvolvida de forma nativa com a biblioteca *NumPy*.

3.6.1 Exatidão (*Accuracy*)

Para a avaliação do acerto determinístico das classes finais, utiliza-se a Exatidão (*Accuracy*). Esta métrica reflete a percentagem bruta de previsões corretas sobre o total de instâncias avaliadas. Embora seja um indicador universal e direto de desempenho, a sua utilidade de forma isolada em dados desportivos pode ser limitada pelo desbalanceamento natural dos desfechos (onde as vitórias caseiras são estatisticamente prevalentes), justificando assim a adoção complementar de métricas focadas na qualidade das probabilidades.

3.6.2 Perda Logarítmica (*Log Loss*)

Para quantificar a entropia e a incerteza das probabilidades emitidas pelo classificador, utiliza-se o *Log Loss*. Esta métrica penaliza severamente o modelo caso este atribua uma probabilidade muito alta a um desfecho incorreto. A fórmula matemática para o cenário multiclasse é definida por:

$$LogLoss = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{ic} \log(p_{ic})$$

Onde N é o número de partidas, C é o número de classes, y_{ic} é o indicador binário (1 se a classe c ocorreu na partida i , 0 caso contrário) e p_{ic} é a probabilidade prevista pelo modelo. Quanto mais próximo de 0 for o valor de *Log Loss*, maior é a segurança estatística do algoritmo.

3.6.3 *Brier Score*

O *Brier Score* (BS) é a métrica de excelência para avaliar a calibração de modelos de previsão desportiva. A sua principal vantagem analítica reside na penalização quadrática do desvio entre a probabilidade estimada e o resultado real verificado.

A formulação original para o cenário multiclasse (aplicada na avaliação estrutural das 3 classes) calcula-se através de:

$$BS = \frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C (p_{ic} - y_{ic})^2$$

O resultado do *Brier Score* varia num intervalo entre 0 e 2 no formato multiclasse (ou 0 e 1 na formulação de previsões binárias, também utilizada neste projeto). Um algoritmo com um *Brier Score* reduzido indica que emite probabilidades altamente ajustadas à frequência empírica dos acontecimentos, validando a fiabilidade do sistema para efeitos de análise desportiva avançada.

Resultados e Discussão

Este capítulo apresenta a avaliação quantitativa e tática dos modelos preditivos perante o conjunto de teste final (épocas 2024/2025 e 2025/2026). A análise divide-se em três eixos: o desempenho do modelo multiclasse, a avaliação do modelo binário (sem empates) e, por fim, a comparação direta entre as duas abordagens. Em todas as etapas, priorizam-se a qualidade e a utilidade das probabilidades geradas, suportando as conclusões em métricas de erro probabilístico (Log Loss e Brier Score) em complemento à exatidão classificativa (Accuracy).

4.1 AVALIAÇÃO MODELO MULTICLASSE (3 CLASSES)

Para garantir uma análise robusta, avaliou-se tanto o acerto global (*Accuracy*) como a qualidade rigorosa das probabilidades geradas (*Log Loss* e *Brier Score Global*).

A Tabela 4.1 demonstra a evolução do desempenho preditivo ao longo das três fases metodológicas: o modelo original base (*Baseline*), o modelo com otimização hiperparamétrica e, por fim, o modelo final após o *Ablation Study* (reduzido a 24 *features*).

Tabela 4.1: Evolução das métricas de desempenho no conjunto de teste (Modelo de 3 Classes).

Modelo (Conjunto de Teste)	<i>Log Loss</i> ↓	<i>Brier Score</i> ↓	<i>Accuracy</i> ↑
<i>Baseline</i> (31 <i>features</i>)	1.2675	0.6798	0.4951
Otimizado (31 <i>features</i>)	0.9608	0.5707	0.5278
Final Reduzido (24 <i>features</i>)	0.9545	0.5660	0.5261

A análise quantitativa revela uma progressão notável na qualidade preditiva. A introdução do *Optuna* foi responsável pela maior correção de trajetória, reduzindo drasticamente as métricas de erro probabilístico (*Log Loss* desceu de 1.2675 para 0.9608) e elevando o acerto global em mais de três pontos percentuais.

Contudo, o aspeto mais relevante do ponto de vista da engenharia de atributos reside no impacto do *Ablation Study*. A remoção das 7 variáveis identificadas como ruído resultou numa ligeira contração do acerto duro (*Accuracy*), mas induziu uma melhoria simultânea no *Log*

Loss (0.9545) e no *Brier Score* (0.5660). Este fenómeno estatístico comprova que, ao eliminar atributos pouco densos, o classificador perdeu ruído aleatório, tornando as suas emissões de probabilidade mais sóbrias, calibradas e matematicamente seguras.

4.1.1 Matriz de Confusão (3 Classes)

A Figura 4.1 apresenta a Matriz de Confusão do Modelo Final Reduzido. O gráfico revela que a classe Vitória da Casa (H) é, de longe, a mais previsível para o algoritmo, obtendo 218 previsões corretas (35.62% do total).




Figura 4.1: Matriz de Confusão para o Modelo Final Reduzido (Cenário de 3 Classes).

Em contrapartida, confirma-se a dificuldade extrema em prever o desfecho de Empate (D). O modelo obteve apenas 3 acertos diretos nesta classe, confundindo a maioria dos empates reais com vitórias (especialmente da casa). Este resultado evidencia a extrema complexidade estatística introduzida pela classe 'D' na fronteira de decisão, motivando a criação subsequente do cenário binário estritamente como um *baseline* analítico. O gráfico de *Precision-Recall* correspondente, detalhado no Anexo B.2, reforça esta queda de precisão para a classe 'D'.

4.1.2 Curva de Calibração (3 Classes)

O principal objetivo deste projeto é obter probabilidades calibradas, não apenas acertos. A Figura 4.2 valida visualmente este objetivo ao apresentar as Curvas de Calibração Global comparativas para os três modelos metodológicos.




Figura 4.2: Curvas de Calibração Global Comparativas: *Baseline*, Otimizado e Final Reduzido.

Como discutido anteriormente, o modelo *Baseline* (linha vermelha tracejada) exibe uma calibração deficiente, com desvios significativos da linha de calibração perfeita (preta pontilhada), particularmente na faixa de probabilidades médias. A introdução do *Optuna* estabilizou a calibração. Ambas as linhas, do Modelo Otimizado (azul contínua) e do Modelo Final Reduzido (verde traço-ponto), seguem a trajetória ideal de forma notavelmente próxima.

Este gráfico é a prova visual crucial do sucesso da *pipeline* metodológica. Ele confirma que a queda nos valores de *Brier Score Global* (da Tabela 4.1) reflete uma verdadeira melhoria na "sinceridade" estatística do algoritmo. As probabilidades emitidas pelo Modelo Final Reduzido não são apenas precisas em termos de acerto global, mas são matematicamente confiáveis e úteis para a tomada de decisão tática. As curvas de calibração específicas por classe, disponíveis no Anexo B.3, confirmam esta tendência para todos os desfechos.

4.2 AVALIAÇÃO MODELO BINÁRIO

A segunda fase da avaliação recaiu sobre a formulação binária do problema, onde os registros de empate (D) foram previamente removidos. O objetivo desta abordagem foi testar o limite preditivo do algoritmo num ambiente de menor entropia, isolando a sua capacidade de distinguir puramente entre a força da equipa visitada (H) e da equipa visitante (A).

À semelhança do procedimento anterior, o modelo foi avaliado no conjunto de teste final (épocas 2024/2025 e 2025/2026). A Tabela 4.2 apresenta a comparação direta entre o modelo *Baseline* e o Modelo Otimizado.

Tabela 4.2: Evolução das métricas de desempenho no conjunto de teste (Modelo Binário).

Modelo Binário (Conjunto de Teste)	<i>Log Loss</i> ↓	<i>Brier Score</i> ↓	<i>Accuracy</i> ↑
<i>Baseline</i> (31 <i>features</i>)	0.7795	0.2324	0.6800
Otimizado (31 <i>features</i>)	0.5437	0.1840	0.7133

Os resultados confirmam a complexidade associada à previsão do empate. Ao estabelecer um *baseline* analítico e simplificar a fronteira de decisão através da remoção desta classe, o desempenho global do classificador sofreu um incremento natural e drástico. O Modelo Otimizado alcançou uma exatidão (*Accuracy*) de 71.33%, valor substancialmente superior ao obtido no cenário multiclasse.

Adicionalmente, a otimização hiperparamétrica através do *Optuna* reduziu o erro probabilístico de forma contundente. O *Log Loss* recuou de 0.7795 para 0.5437, enquanto o *Brier Score* global desceu de 0.2324 para 0.1840. Esta contração harmónica das métricas de erro prova que o modelo binário alcançou um patamar superior de assertividade e de calibração nas suas estimativas de probabilidade.

4.2.1 Matriz de Confusão (2 Classes)

A ausência de ruído reflete-se de forma clara na estrutura das previsões. A Figura 4.3 ilustra a Matriz de Confusão do modelo binário otimizado, evidenciando uma forte concentração de acertos na diagonal principal.




Figura 4.3: Matriz de Confusão para o Modelo Otimizado (Cenário Binário).

O algoritmo previu corretamente 214 vitórias caseiras e 107 vitórias como visitante. A dispersão de falsos positivos e falsos negativos é equilibrada e francamente contida. A robustez desta capacidade discriminatória é suportada pelas curvas de *Precision-Recall*, cujo *Average Precision* (AP) atingiu os 0.82 no modelo otimizado (gráficos detalhados no Anexo C.2).

4.2.2 Curva de Calibração (2 Classes)

Por fim, no que concerne à calibração do modelo, a Figura 4.4 atesta a excelência das probabilidades geradas para a classe Vitória da Casa (H).





Figura 4.4: Curva de Calibração da Classe H: Comparação entre *Baseline* e Otimizado (Modelo Binário).


Observa-se que o modelo *Baseline* (linha vermelha tracejada) sofria de sobreconfiança em várias faixas de probabilidade. A aplicação do *Optuna* (linha azul contínua) corrigiu esta distorção, alinhando a frequência real observada quase perfeitamente com a probabilidade média prevista (linha preta pontilhada). Isto significa que, num cenário sem empates, as probabilidades emitidas são matematicamente fiáveis para apoiar decisões táticas.

4.3 ANÁLISE COMPARATIVA DOS MODELOS

O contraste entre o modelo multiclasse e o modelo binário permite compreender como o algoritmo ajusta a sua fronteira de decisão perante a ausência do empate. Para este efeito, colocaram-se lado a lado as hierarquias de importância de variáveis (*Feature Importance*) geradas por ambos os sistemas.



(a) Importância relativa no Modelo Multiclasse Final (24 *features*).



(b) Importância relativa no Modelo Binário Otimizado (31 *features*).

Figura 4.5: Comparação vertical das importâncias das variáveis.

A observação da Figura 4.5a revela que o modelo de três classes depende fortemente de métricas absolutas da equipa visitada para estabelecer o seu ponto de referência. Atributos como a diferença de golos caseira (**HomeGD**) e o *ranking* da casa (**HomeRank**) assumem um peso crítico, figurando no topo da hierarquia logo a seguir aos diferenciais macro (**GDpg_Diff** e **PPG_Diff**). Adicionalmente, a variável **Stadium** apresenta uma relevância considerável. Isto sugere que, num cenário de alta incerteza (com empates), o algoritmo apoia-se no fator empírico do "fator casa" e na solidez defensiva caseira para estruturar as probabilidades.

Em contrapartida, a Figura 4.5b ilustra uma mudança drástica no paradigma de decisão do modelo binário. Removida a "zona cinzenta" do empate, o foco principal do algoritmo desloca-se de forma agressiva para a capacidade real da equipa visitante. Atributos isolados forasteiros, como a diferença de golos fora (**AwayGD**), o volume de vitórias do visitante (**AwayW**) e a diferença de golos por jogo forasteiro (**AwayGDpg**), disparam para o topo da hierarquia de importância.

Esta transição estatística mapeia na perfeição a realidade tática do futebol de alta competição. Num cenário onde o jogo obrigatoriamente pende para um vencedor, o modelo assume a força caseira como o desfecho base (confirmado pela distribuição de dados, onde a classe H é maioritária). Para contrariar esta inércia e prever o desfecho oposto, o algoritmo exige provas de letalidade ofensiva e defensiva por parte da equipa visitante.

Apesar destas diferenças comportamentais, ambos os modelos convergem num ponto fundamental: o diferencial normalizado de golos por jogo (**GDpg_Diff**) consolida-se como o indicador supremo da disparidade de forças. Em linha com a literatura de análise desportiva, métricas baseadas em golos, como o saldo de golos estabilizado ao longo do tempo, tendem a captar de forma mais robusta a força subjacente das equipas e a preservar mais informação estatística do que métricas discretas baseadas apenas em resultados, como pontos ou vitórias acumuladas.

Conclusões e Trabalho Futuro

Neste capítulo são apresentadas as conclusões finais do desenvolvimento e da avaliação dos modelos preditivos. É apresentado um balanço crítico sobre o impacto da remoção do empate e da otimização de atributos na calibração probabilística do algoritmo. Por fim, delineiam-se os eixos fundamentais para investigações futuras, abordando novas fontes de dados.

Este trabalho apresentou o desenvolvimento e a avaliação de uma pipeline de modelação preditiva aplicada à Primeira Liga Portuguesa. Através do algoritmo *XGBoost*, explorou-se o impacto da engenharia de atributos, da otimização hiperparamétrica e da redução da dimensionalidade do alvo nos desfechos desportivos.

Os resultados quantitativos validaram de forma clara as hipóteses metodológicas formuladas. A utilização do cenário binário estritamente como um *baseline* analítico demonstrou que o desfecho de empate constitui o principal desafio técnico da modelação, introduzindo uma elevada complexidade não linear na fronteira de decisão do algoritmo. Ao simplificar o espaço preditivo com a remoção desta classe, foi um reflexo natural que a exatidão (*Accuracy*) saltasse de 52,61% para 71,33%, acompanhada por uma robusta melhoria na fiabilidade probabilística, refletida na descida do *Brier Score* para 0,1840.

Adicionalmente, provou-se que a calibração probabilística é um indicador de desempenho mais maduro e fiável para cenários reais do que a mera análise determinística de acertos brutos. O *Ablation Study* confirmou que o corte cirúrgico de variáveis com contribuição residual eliminou ruído estatístico de fundo, resultando em previsões mais sóbrias e matematicamente seguras.

5.1 TRABALHO FUTURO

Como propostas para a evolução e continuidade desta linha de investigação, destacam-se os seguintes eixos estruturais de desenvolvimento:

- **Modelação Dinâmica ao Intervalo (*Live/In-Play*):** O plano inicial deste projeto previa o desenvolvimento de um modelo secundário focado em previsões ao intervalo.

Este sistema receberia como variáveis de entrada tanto as probabilidades pré-jogo (atuando como uma linha de base estável) como as estatísticas em tempo real da primeira parte (remates, posse de bola, cantos, etc.). Contudo, a implementação foi inviabilizada devido à extrema dificuldade em obter dados históricos granulares e fiáveis para partidas antigas, bem como pela complexidade tática de estruturar uma pipeline automatizada para jogos a decorrer.

- **Integração de Dados Climáticos Oficiais Granulares:** Substituir a variável macro e calendarística *WeatherSeason* pela integração direta de dados meteorológicos históricos de alta resolução (temperatura, velocidade do vento e taxa de precipitação). Idealmente, estes dados seriam obtidos através da API oficial do Instituto Português do Mar e da Atmosfera (IPMA). Superando as limitações de dados em falta identificadas neste artigo para os estádios fora dos eixos metropolitanos de Lisboa e Porto, a inclusão destas variáveis à hora exata do apito inicial permitiria capturar o verdadeiro impacto do estado do relvado e do clima no rendimento desportivo.
- **Incorporação de Variáveis de Mercado e Valor Financeiro:** Enriquecer a matriz preditiva com dados económicos atualizados, tais como o valor de mercado total de cada plantel e a avaliação financeira do onze inicial de cada partida (recorrendo a plataformas especializadas como o *Transfermarkt*). Estas variáveis atuariam como um indicador de qualidade técnica intrínseca, complementando as métricas puramente estatísticas.
- **Mitigação do Desbalanceamento de Classes:** O desfecho de empate provou ser o maior obstáculo técnico na formulação multiclasse. Futuras iterações do modelo devem abordar esta limitação da fronteira de decisão através da atribuição direta de pesos às classes (*class weights*) no algoritmo de treino, da exploração de técnicas de *over-sampling* para a classe minoritária (recorrendo a algoritmos como o *SMOTE*), ou do desenvolvimento de funções de perda personalizadas (*custom loss functions*) que penalizem de forma mais agressiva e assimétrica as falhas na previsão de empates. Adicionalmente, o *feature engineering* pode ser direcionado para perfilar equipas com características táticas propensas a este resultado (por exemplo, defesas estatisticamente robustas conjugadas com letalidade ofensiva reduzida).

Referências

- [1] M. J. Maher, «Modelling association football scores,» *Statistica Neerlandica*, vol. 36, n.º 3, pp. 109–118, 1982.
- [2] M. J. Dixon e S. G. Coles, «Modelling association football scores and inefficiencies in the football betting market,» *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, n.º 2, pp. 265–280, 1997.
- [3] F. Rodrigues e A. Pinto, «Prediction of football match results with Machine Learning,» *Procedia Computer Science*, vol. 204, pp. 463–470, 2022.
- [4] E. F. E. Atta Mills, Z. Deng, Z. Zhong e J. Li, «Data-driven prediction of soccer outcomes using enhanced machine and deep learning techniques,» *Journal of Big Data*, vol. 11, n.º 1, p. 170, 2024.
- [5] R. Beal, S. E. Middleton, T. J. Norman e S. D. Ramchurn, «Combining Machine Learning and Human Experts to Predict Match Outcomes in Football: A Baseline Model,» *AAAI Conference on Artificial Intelligence*, 2021.
- [6] M. N. Razali, A. Mustapha, S. A. Mostafa e S. S. Gunasekaran, «Football Matches Outcomes Prediction Based on Gradient Boosting Algorithms and Football Rating System,» *Human Factors in Software and Systems Engineering*, vol. 61, pp. 57–66, 2022.
- [7] S. Harish, A. Abishek Kevin, U. Harsha Vardhan e P. Sharon Femi, «Expected Goals Prediction in Football using XGBoost,» *ESP Journal of Engineering & Technology Advancements*, vol. 3, n.º 1, pp. 21–26, 2023.
- [8] T. Decroos e J. Davis, «Interpretable Prediction of Goals in Soccer,» *KU Leuven, Department of Computer Science*, 2019.
- [9] L. Egidi e N. Torelli, «Comparing Goal-Based and Result-Based Approaches in Modelling Football Outcomes,» *Social Indicators Research*, vol. 156, pp. 801–813, 2021.
- [10] C. Yeung, R. Bunker, R. Umemoto e K. Fujii, «Evaluating soccer match prediction models: a deep learning approach and feature optimization for gradient-boosted trees,» *Machine Learning*, vol. 113, pp. 7541–7564, 2024.
- [11] G. W. Brier, «Verification of forecasts expressed in terms of probability,» *Monthly Weather Review*, vol. 78, n.º 1, pp. 1–3, 1950.
- [12] Football-Data.co.uk, *Football-Data*, [Online; acedido em 20-maio-2026], 2026. URL: <https://www.football-data.co.uk>.

Gráficos de Importância de Atributos (Modelos *Baseline*)

Neste anexo encontram-se os gráficos de importância de variáveis (*Feature Importance*) gerados a partir dos modelos *baseline* (sem otimização de hiperparâmetros). Estes gráficos servem como registo do ponto de partida da modelação e justificam as alterações comportamentais observadas após a aplicação do *Optuna*.




Figura A.1: Importância relativa das 31 variáveis no modelo *Baseline* de 3 Classes.




Figura A.2: Importância relativa das 31 variáveis no modelo *Baseline* Binário (2 Classes).

Gráficos Complementares (Modelo de 3 Classes)

Este anexo reúne as métricas visuais secundárias que suportam as avaliações probabilísticas e classificativas do modelo de três classes detalhadas no Capítulo 4, seção 4.1.

B.1 MATRIZES DE CONFUSÃO

As figuras abaixo ilustram a distribuição de previsões antes da otimização de hiperparâmetros, e após a otimização mas antes do *Ablation Study*.




Figura B.1: Matriz de Confusão para o Modelo *Baseline* (3 Classes).




Figura B.2: Matriz de Confusão para o Modelo Otimizado (3 Classes).

B.2 CURVAS DE *PRECISION-RECALL*

Os gráficos abaixo mostram o compromisso entre a Precisão (*Precision*) e a Sensibilidade (*Recall*) nas três fases de desenvolvimento do projeto. A observação do Modelo Final (Figura B.5) confirma o comportamento frágil da classe de Empate (linha turquesa), cuja área sob a curva é drasticamente inferior devido à natureza ruidosa deste desfecho.




Figura B.3: Curva de *Precision-Recall* para o Modelo *Baseline* (3 Classes).




Figura B.4: Curva de *Precision-Recall* para o Modelo Otimizado (3 Classes).




Figura B.5: Curva de *Precision-Recall* para o Modelo Final Reduzido (3 Classes).

B.3 CURVAS DE CALIBRAÇÃO POR CLASSE

As figuras seguintes desconstruem a calibração global do Modelo Final para analisar a calibração em cada desfecho isolado. Nota-se que a remoção de variáveis ruidosas efetuado no *Ablation Study* (linha verde traço-ponto) aproximou as frequências reais da diagonal perfeita (linha preta pontilhada) em todas as frentes, validando a descida do *Brier Score*.




Figura B.6: Curva de Calibração para a Classe Vitória da Casa (H).




Figura B.7: Curva de Calibração para a Classe Empate (D).




Figura B.8: Curva de Calibração para a Classe Vitória do Visitante (A).

Gráficos Complementares (Modelo Binário)

Este anexo reúne as métricas visuais secundárias que dão suporte às avaliações classificativas e probabilísticas do modelo binário (cenário sem empates) apresentadas no Capítulo 4, seção 4.2.

C.1 MATRIZ DE CONFUSÃO DO MODELO *BASLINE*

A Figura C.1 ilustra a distribuição de previsões do classificador binário antes da otimização de hiperparâmetros. A comparação entre este gráfico e a versão final otimizada (apresentada no corpo principal) evidencia o impacto positivo do *Optuna* na redução dos falsos positivos, especialmente nas previsões de vitórias como visitante (A).




Figura C.1: Matriz de Confusão para o Modelo *Baseline* (Cenário Binário).

C.2 CURVAS DE *PRECISION-RECALL*

As figuras seguintes apresentam o comportamento da Precisão (*Precision*) em função da Sensibilidade (*Recall*) para as classes. O processo de otimização hiperparamétrica expandiu de forma nítida a área sob a curva, elevando a métrica de Precisão Média (*Average Precision* - AP) de 0.78 (Figura C.2) para 0.82 (Figura C.3). Isto comprova uma maior estabilidade do algoritmo na discriminação de resultados desportivos puros.




Figura C.2: Curva de *Precision-Recall* - Modelo *Baseline* (Cenário Binário).




Figura C.3: Curva de *Precision-Recall* - Modelo Otimizado (Cenário Binário).